

1. FLOPs (S, B)

$B \times 0.9$
Conv $7 \times 7, s=2$
MaxPool, $s=2$

$B \times 3 \times 5 \times 5$
 $B \times 32 \times \frac{5}{2} \times \frac{5}{2}$
 $B \times 32 \times \frac{5}{4} \times \frac{5}{4}$

Conv 5×5
Conv $3 \times 3, s=2$
Conv 1×1
Conv $3 \times 3, s=2$
Conv 1×1

$B \times 64 \times \frac{5}{4} \times \frac{5}{4}$
 $B \times 128 \times \frac{5}{8} \times \frac{5}{8}$
 $B \times 256 \times \frac{5}{8} \times \frac{5}{8}$
 $B \times 256 \times \frac{5}{16} \times \frac{5}{16}$
 $B \times 512 \times \frac{5}{16} \times \frac{5}{16}$

Global Avg Pool
Linear
Linear

$B \times 512$
 $B \times 256$
 $B \times 100$

Допущение: MAC = 2 FLOPs, учитываем MAC сверточных и полносвязных слоев, операции RELU, MAXPool и Global Avg Pool считаем не учитываем.

Для каждого элемента сверточной kernel $C_{in} \times K^2$ операций MAC, где K - размер ядра: $B \times H_{out} \times W_{out} \times C_{out}$, нормируя:

$$F_{conv} = 2 \times B \times H_{out} \times W_{out} \times C_{out} \times C_{in} \times K^2$$

$$F_{linear} = 2 B N_{in} N_{out}$$

Рассчитаем FLOPs:

Conv 7×7
 $3 \rightarrow 32$
 $s=2$

$$1) F_1 = 2 B \left(\frac{5}{2}\right)^2 \cdot 32 \cdot 3 \cdot 7^2 =$$

$$= 2 B \frac{5^2}{4} \cdot 32 \cdot 3 \cdot 49 =$$

$$= 2352 B S^2$$

Conv 5×5
 $32 \rightarrow 64$

$$2) F_2 = 2 B \left(\frac{5}{4}\right)^2 \cdot 64 \cdot 32 \cdot 5^2 =$$

$$= 2 B \frac{5^2}{16} \cdot 64 \cdot 32 \cdot 25 =$$

$$= 6400 B S^2$$

Conv 3×3
 $64 \rightarrow 128$
 $s=2$

$$3) F_3 = 2 B \left(\frac{5}{8}\right)^2 \cdot 128 \cdot 64 \cdot 3^2 =$$

$$= 2 B \frac{5^2}{64} \cdot 128 \cdot 64 \cdot 9 =$$

$$= 2304 B S^2$$

Conv 1×1
 $128 \rightarrow 256$

$$4) F_4 = 2 B \left(\frac{5}{8}\right)^2 \cdot 256 \cdot 128 =$$

$$= 1024 B S^2$$

Conv 3×3
 $256 \rightarrow 256$
 $s=2$

$$5) F_5 = 2 B \left(\frac{5}{16}\right)^2 \cdot 256 \cdot 256 \cdot 3^2 =$$

$$= 2 B \frac{5^2}{256} \cdot 256 \cdot 256 \cdot 9 =$$

$$= 4608 B S^2$$

Conv 1×1
 $256 \rightarrow 512$

$$6) F_6 = 2 B \left(\frac{5}{16}\right)^2 \cdot 512 \cdot 256 =$$

$$= 1024 B S^2$$

Linear
 $512 \rightarrow 256$

$$7) F_7 = 2 B \cdot 512 \cdot 256 =$$

$$= 262144 B$$

Linear
 $256 \rightarrow 100$

$$8) F_8 = 2 B \cdot 256 \cdot 100 =$$

$$= 51200 B$$

$$FLOPs(S, B) = F_1 + F_2 + \dots + F_8 = (2352 + 6400 + 2304 + 1024 + 4608 + 1024) B S^2 +$$

$$+ (262144 + 51200) B = 12712 B S^2 + 313344 B$$

2. Memory

Для прямой прохода в режиме eval() и torch.inference_mode() с типом данных FP32

Допущения: 1) Одно число FP32 занимает 4 байта; 2) Входной тензор и параметры имеют уже размещены на GPU в начале прямого прохода; 3) ReLU(inplace=True) не создаёт отдельный тензор размера активации; 4) промежуточный тензор освобождается после того, как перестанет использоваться

Сначала найдём память параметров, у всех свёрток bias=False, а у всех полносвязных слоёв умножим веса и смещения.

$$P_{conv1} = 3 \cdot 32 \cdot 7^2 = 4704$$

$$P_{conv2} = 32 \cdot 64 \cdot 5^2 = 51200$$

$$P_{conv3} = 64 \cdot 128 \cdot 3^2 = 73728$$

$$P_{conv4} = 128 \cdot 256 \cdot 1^2 = 32768$$

$$P_{conv5} = 256 \cdot 256 \cdot 3^2 = 589824$$

$$P_{conv6} = 256 \cdot 512 \cdot 1^2 = 131072$$

$$P_{conv} = P_{conv1} + P_{conv2} + \dots + P_{conv6} = 883296$$

$$P_{linear1} = 512 \cdot 256 + 256 = 131328$$

$$P_{linear2} = 256 \cdot 100 + 100 = 25700$$

$$\text{Общее число параметров: } P = 883296 + 131328 + 25700 = 1040324$$

Они занимают $M_{param} = 4P = 4 \cdot 1040324 = 4161296$ байт
Теперь найдём размеры активаций в явном виде:

Тензор	Число элементов
Вход	$3BS^2$
Conv 7x7	$8BS^2$
MaxPool	$2BS^2$
Conv 5x5	$4BS^2$
Conv 3x3	$2BS^2$
Conv 1x1	$4BS^2$
Conv 3x3	BS^2
Conv 1x1	$2BS^2$
Global Avg Pool	512B
Linear 1	256B
Linear 2	100B

Оценим также, что занимает активированно агу, тензоров
будет при входе, первом свёртке и MaxPool $\approx 13BS^2$

значения показана, что MaxPool временно создаёт массив типа int64 для 32-ов входов их число равно $2BS^2$, а один элемент int64 занимает 8 байт, тогда индексы занимают $8 \cdot 2BS^2 = 16BS^2$ байт.

$$\text{Тогда } \text{Memory}(S, B) = 4P + 4(3BS^2 + 8BS^2 + 2BS^2) + 16BS^2 = \\ = 4161296 + 68BS^2 \text{ байт}$$

3. Bytes(S, B)

Допущения: 1) все нейроны имеют тип FP32 - один элемент занимает 4 байта; 2) для каждого входа считаем одно чтение со входа и одну запись входов; 3) дополнительные чтения внутри свёрток, работа кэша и временные буферы не учитываемся. Выходим размерности числа элементов из прошлого раздела

размеры расширенных нейронов:

$$T_p = (3+8) + (8+2) + (2+4) + (4+2) + (2+4) + (4+1) + (1+2) + 2 = \\ = 49BS^2$$

Число элементов при пересогде в главной части сети:

$$T_h = 512B + (512+256)B + (256+100)B = \\ = 1636B$$

Базу учёта ReLU мы считаем и записываем:

$$T_L = 49BS^2 + 1636B$$

Умножаем ReLU, после нейронов из 6-ти свёрток ReLU и после первого Linear. Каждый ReLU считаем и перезаписываем свой нейрон, но вход равен удвоенному размеру нейронов.

$$T_R = 2(8+4+2+4+1+2)BS^2 + 2 \cdot 256B = \\ = 42BS^2 + 512B$$

Общий объём в элементах:

$$T = T_L + T_R + P = \\ = (49BS^2 + 1636B) + (42BS^2 + 512B) + 1040324 =$$

$= 91BS^2 + 2148B + 1040324$, один элемент FP32 занимает 4 байта, тогда получим:

$$\text{Bytes}(S, B) = 4T = 364BS^2 + 8592B + 4161296 \text{ байт.}$$

4. Latency (S, B, θ)

$\theta = (t_0, R, W)$, где t_0 - постоянная задержка на запуск инициации процесса, с;

R - нормализованная скорость вычислений, FLOPs/c

W - нормализованная скорость передачи данных, байт/c.

Если скорость вычислений R , то время вычислений работы:

$$T_{\text{compute}}(S, B) = \frac{\text{FLOPs}(S, B)}{R} = \frac{(177125^2 + 313344)B}{R}$$

Если скорость передачи данных W , то время работы с данными:

$$T_{\text{memory}}(S, B) = \frac{\text{Bytes}(S, B)}{W} = \frac{364BS^2 + 8592B + 4161296}{W}$$

Далее: вычисления и работа с данными могут частично перекрываться, поэтому время основной работы приближаем большим из этих двух значений, постоянные задержки t_0 прибавим отдельно:

$$\text{Latency}(S, B, \theta) \approx t_0 + \max\left(\frac{(177125^2 + 313344)B}{R}, \frac{364BS^2 + 8592B + 4161296}{W}\right)$$

параметры t_0, R, W подбираются по конкретным измерениям

- launch-bound: Если $t_0 \gg \max(T_{\text{compute}}, T_{\text{memory}})$, то время примерно постоянно $\text{Latency}(S, B, \theta) \approx t_0$

- memory-bound: Если $T_{\text{memory}} > T_{\text{compute}}$ и $T_{\text{memory}} \gg t_0$, то $\text{Latency}(S, B, \theta) \approx \frac{\text{Bytes}(S, B)}{W}$

- compute-bound: Если $T_{\text{compute}} > T_{\text{memory}}$ и $T_{\text{compute}} \gg t_0$, то $\text{Latency}(S, B, \theta) \approx \frac{\text{FLOPs}(S, B)}{R}$

5. Energy.

$$\text{Energy}(S, B, \theta) = P_0 \cdot \text{Latency}(S, B, \theta) + \epsilon_F \cdot \text{FLOPs}(S, B) + \epsilon_B \cdot \text{Bytes}(S, B)$$

- P_0 - базовая мощность всей GPU
- ϵ_F нормированная добавка энергии на одну операцию.
- ϵ_B нормированная добавка энергии на один переданный байт.

Допущение: мощность GPU во время прохода приближена базовой составляющей, действующей на протяжении всего времени, и добавками, связанными событиями вычисления и переноса данных.

Используя уже найденные результаты для $\text{Latency}(S, B, \theta)$,

$\text{FLOPs}(S, B)$, $\text{Bytes}(S, B)$, получим выражение для $\text{Energy}(S, B, \theta)$

$$\text{Energy}(S, B, \theta) = P_0 \left[t_0 + \max\left(\frac{(177125^2 + 313344)B}{R}, \frac{364BS^2 + 8582B + 4161296}{W}\right) \right] +$$

$$+ \epsilon_F B(177125^2 + 313344) + \epsilon_B (364BS^2 + 8582B + 4161296)$$